Testing AI-Based Systems

اختبار الأنظمة القائمة على AI

Core outcome: Use risk-based test levels and statistical oracles for reliable LLM and AI evaluation.

الفكرة الأساسية: لا يكفي أن يعطي الـ AI إجابة تبدو جيدة؛ وثّق Oracle، عينة، تكرار، ومعيار قبول.

4.1 Introduction to Testing AI-Based Systems

4.1.1 Locked and Adaptive AI-Based Systems

الشرح والمبادئ الأساسية · AR

• Locked AI لا يحدّث تعلمه أثناء التشغيل، بينما Adaptive AI يغيّر السلوك استجابة للتغير بعد النشر. حتى locked LLM قد ينتج نتائج مختلفة بسبب sampling وfloating point. أي تحديث للإصدار يحتاج regression testing.

English definition / principle · EN

• Locked AI-based system: A system whose learned behavior is not autonomously updated in operation. Adaptive AI-based system: A system that learns or adapts during operation, requiring continuous monitoring and reassessment.

🧪 **تطبيق على THL:** وثّق model/prompt/rubric version مع كل تقرير؛ لا تقارن نتائج إصدارات مختلفة دون تسجيل فرق النسخ.

4.1.2 Rationale for a Statistical Approach to Testing AI-Based Systems

الشرح والمبادئ الأساسية · AR

• النتائج الاحتمالية لا يمكن الحكم عليها من مثال واحد. استخدم عينة ممثلة لتوزيع التشغيل، حدود ثقة/uncertainty، واختبارات لفئات حرجة. قيّم معدلات أخطاء النوعين والمخاطر المجتمعية.

English definition / principle · EN

• Statistical testing: Evaluating a probabilistic system using an adequately sized sample, error measures and uncertainty rather than a single deterministic pass/fail example.

🧪 **تطبيق على THL:** شغّل نفس نوع المقابلة على مجموعة Golden ممثلة وقارن precision/recall مع thresholds موافق عليها.

4.1.3 Test Oracles for AI-Based Systems

الشرح والمبادئ الأساسية · AR

• Test oracle هو مرجع تحديد المتوقع، لكنه صعب مع اللغة الطبيعية والغموض وعدم الحتمية. البدائل: goldens، خبراء، حدود مقبولة، علاقات metamorphic، proxy oracles ومقارنة نسخ.

English definition / principle · EN

• Test oracle: The mechanism or source used to determine expected results. Oracle problem: Difficulty establishing an unambiguous correct outcome for a test input.

🧪 **تطبيق على THL:** اربط كل Observation بنص المرشح والدليل الزمني؛ لا تعتبر حكم LLM آخر مرجعًا نهائيًا.

4.2 Testing Generative AI and Large Language Models

4.2.1 Testing Generative AI

الشرح والمبادئ الأساسية · AR

• اختبر factuality وgroundedness وrelevance وinstruction following وtoxicity وprivacy، مع اختلاف الصياغة واحتمال تكرار مختلف. افصل quality checks عن functional hard constraints.

English definition / principle · EN

• Groundedness: The degree to which generated claims are supported by supplied evidence. Prompt injection: Malicious or unintended instructions embedded in an input that attempt to override trusted instructions.

🧪 **تطبيق على THL:** لا يُسمح لـ AI Interviewer باختراع أسئلة خارج بنك الأسئلة المحفوظ؛ ونتيجة المقابلة يجب أن تدعمها الإجابات.

4.2.2 Red Teaming

الشرح والمبادئ الأساسية · AR

• Red teaming اختبار عدائي منظم لتحدي ضوابط الأمان، كشف الاستخدام الضار وتسريب المعلومات والتحيز أو تجاوز الصلاحيات. تجارب الهجوم تُجرى ببيانات آمنة وتصريح واضح.

English definition / principle · EN

• AI red teaming: A structured, adversarial evaluation intended to discover vulnerabilities, harmful behavior or weaknesses in safety and security controls.

🧪 **تطبيق على THL:** أدخل تعليمات مخادعة ضمن إجابة مرشح صناعي لاختبار عدم التلاعب بالتقييم.

4.2.3 Hands-on Exercise: Exploratory Testing of a Large Language Model

الشرح والمبادئ الأساسية · AR

• عملي: جهز charters قصيرة، جرّب prompts متنوعة ومربكة، دوّن التغيرات والمخاطر، ثم حوّل النتائج القابلة للتكرار إلى test cases وآليات رصد.

English definition / principle · EN

• Exploratory testing: Simultaneous learning, test design and execution driven by observations from system behavior.

🧪 **تطبيق على THL:** أنشئ ملاحظات Test Charter: evidence-grounding، question-bank adherence، safety، وuncertainty.

4.3 Test Levels and Machine Learning Systems ↑

4.3.1 Test Levels for Machine Learning Systems

الشرح والمبادئ الأساسية · AR

• تشمل اختبارات البيانات، النموذج، المكونات والـ pipeline، التكامل، النظام، القبول والنشر؛ لكل مستوى مقياس وoracle مختلف. لا تختزلها في E2E فقط.

English definition / principle · EN

• Test level: A distinct grouping of test activities conducted for a specific purpose and on a particular part of the system.

🧪 **تطبيق على THL:** اختبر API للمقابلات مستقلًّا، ثم report generator، ثم E2E وصولًا لنتائج المرشح.

4.3.2 Risk-Based Testing of Machine Learning Systems

الشرح والمبادئ الأساسية · AR

• حدّد أولوية الاختبارات بناءً على احتمال الضرر وتأثيره: رفض خاطئ، كشف معلومات، ادعاءات غير صحيحة، تمييز، تعطل تقرير. استخدم مقاييس قبول أقوى للمخاطر العالية.

English definition / principle · EN

• Risk-based testing: Planning and prioritizing tests according to product risks, their likelihood and their impact.

🧪 **تطبيق على THL:** اجعل اختبارات false rejection والخصوصية والـ fabricated qualifications من أولويات P0.

📖 Important Definitions — English

المصطلحات الآتية مكتوبة بالإنجليزي لتثبيت لغة الامتحان والفهم العلمي. التعريفات صياغة تعليمية وليست اقتباسات حرفية من ISTQB.

Test Oracle
A mechanism for determining the expected or correct result of a test.

Statistical Testing
Assessing performance with representative samples and uncertainty estimates.

Locked AI
A model that does not autonomously update its learned behavior in operation.

Adaptive AI
A model that learns or adapts during operation.

Groundedness
Support of generated claims by verified, relevant source evidence.

Red Teaming
Adversarial evaluation that challenges safety, security and misuse controls.

Prompt Injection
Attacker-controlled input that attempts to redirect an AI system against trusted instructions.

Risk-Based Testing
Prioritization of testing based on identified likelihood and impact of failure.

🧠 Numbered Mind Map · الخريطة الذهنية بالأرقام

Chapter 4
Testing AI-Based Systems
اختبار الأنظمة القائمة على AI

- 4.1.1 Locked and Adaptive AI-Based Systems
- 4.1.2 Rationale for a Statistical Approach to Testing AI-Based Systems
- 4.1.3 Test Oracles for AI-Based Systems
- 4.2.1 Testing Generative AI
- 4.2.2 Red Teaming
- 4.2.3 Hands-on Exercise: Exploratory Testing of a Large Language Model
- 4.3.1 Test Levels for Machine Learning Systems
- 4.3.2 Risk-Based Testing of Machine Learning Systems

الترقيم مبني على فهرس ISTQB CT-AI v2.0 الرسمي، وتلخيص المحتوى أداة تعليمية. راجع الـ Syllabus لكل تفاصيل Learning Objectives والأسئلة الرسمية.