Input Data Testing for Machine Learning Systems

اختبار بيانات الإدخال للتعلم الآلي

الفكرة الأساسية: ابدأ من جودة البيانات قبل الحكم على جودة النموذج أو اتهامه بالهلوسة.

Core outcome: Validate representation, labels, constraints and pipelines before measuring model output quality.

5.1 Input Data Testing for Machine Learning Systems

5.1.1 Input Data Risks and Mitigations

الشرح والمبادئ الأساسية · AR

• المخاطر: data bias، تسميم البيانات، عدم موثوقية المصدر، عدم الاتساق، missing/invalid values، توزيع غير ممثل، وتسريب بيانات بين المجموعات. التخفيف: Data provenance وEDA وقيود Schema وسياسات إدارة مجموعات البيانات.

English definition / principle · EN

• Data provenance: Information documenting where data came from and how it was collected, transformed or annotated. Data poisoning: Malicious corruption of data intended to alter learned behavior.

🧪 **تطبيق على THL:** ارصد غياب النص أو الصوت أو زمن السؤال والـ candidate ID قبل توليد أي Observation.

5.1.2 Testing for Bias

الشرح والمبادئ الأساسية · AR

• الانحياز قد ينشأ من بيانات غير ممثلة أو قرارات وسم متحيزة أو طريقة اختيار العينة أو thresholds. افحص paired examples، cohorts، balanced datasets، مع توثيق حجم العينة وعدم اليقين.

English definition / principle · EN

• Data bias: Systematic distortion in a dataset that can lead to unrepresentative or unfair learned outcomes. Disparate impact analysis: Comparing outcome rates across defined groups.

🧪 **تطبيق على THL:** قارن إجابات مرشحين صناعية بنفس مستوى المهارة مع تغيير سمات غير مرتبطة بالوظيفة.

5.1.3 Data Pipeline Testing

الشرح والمبادئ الأساسية · AR

• اختبر ETL أو feature creation → store → transform → ingest: سلامة schema، تكرار البيانات، permissions، late events، missing values، والأداء. احتفظ بـ checks بعد كل خطوة.

English definition / principle · EN

• Data pipeline testing: Verifying correctness, completeness, integrity and reliability of data as it moves through processing stages.

🧪 **تطبيق على THL:** تأكد أن transcript segments مرتبطة بالشخص والجلسة والسؤال الصحيح بعد المعالجة.

5.1.4 Testing for Data Representativeness

الشرح والمبادئ الأساسية · AR

• Dataset ممثلة تعكس نطاق التشغيل: لغات، لهجات، فئات، درجات صعوبة وإجابات صحيحة/خاطئة وصمت. عدم التمثيل قد يخفي فشلًا خطيرًا مهما بلغت accuracy العامة.

English definition / principle · EN

• Representativeness: The extent to which the evaluation data reflect the relevant characteristics and distributions of the intended operating population.

🧪 **تطبيق على THL:** ضمّن عربي/إنجليزي/مزيج، ضوضاء، إجابات قصيرة، وإجابات كاملة في مجموعة التقييم.

5.1.5 Dataset Constraint Testing

الشرح والمبادئ الأساسية · AR

• عرّف قيود النوع والمدى والطول والارتباط: IDs صالحة، زمن غير سالب، labels ضمن قيم معروفة، uniqueness حيث يلزم، وعدم وجود بيانات حساسة غير ضرورية.

English definition / principle · EN

• Dataset constraint: An explicit rule that valid dataset values, structures or relationships must satisfy.

🧪 **تطبيق على THL:** assert لا توجد جلسة بلا Candidate ID، ولا Evaluation Score خارج المجال المعتمد.

5.1.6 Label Correctness Testing

الشرح والمبادئ الأساسية · AR

• سوء labeling يعني benchmark مضللًا. اكتب annotation guidelines، استخدم SME reviewers مستقلين، سوِّ خلافاتهم، واحسب agreement عند الحاجة. لا تولِّ golden labels بواسطة النموذج الذي تختبره نفسه.

English definition / principle · EN

• Label correctness: Agreement between a dataset label and the appropriate verified reference. Inter-annotator agreement: Consistency of labeling among independent reviewers.

🧪 **تطبيق على THL:** راجع 20 إجابة صناعية مع SME قبل اعتبارها Goldens لتقييم المهارات.

5.1.7 Hands-on Exercise: Input Data Testing

الشرح والمبادئ الأساسية · AR

• عملي: افحص label، outliers، duplicates، completeness، schema، representation، consistency وprovenance؛ احفظ قائمة violations وخطة تصحيح.

English definition / principle · EN

• Hands-on objective: Write and execute repeatable checks that reveal input quality defects before model or report evaluation.

🧪 **تطبيق على THL:** نفذ Pandas asserts على candidate_evaluation.csv وأدخل بيانات خاطئة لتتأكد أن الاختبار يفشل.

📖 Important Definitions — English

المصطلحات الآتية مكتوبة بالإنجليزي لتثبيت لغة الامتحان والفهم العلمي. التعريفات صياغة تعليمية وليست اقتباسات حرفية من ISTQB.

Data Bias
Systematic distortion in data that can impair fairness, representativeness, or prediction quality.

Data Provenance
Documented origin and transformations of a dataset.

Data Pipeline
Processes that ingest, transform, validate and deliver data for ML use.

Representativeness
Coverage of the important distributions and populations of the intended operating setting.

Dataset Constraint
Rule that allowed data fields, values, types and relationships must satisfy.

Label Correctness
Validity of an assigned ground-truth label against an independent reference.

Data Poisoning
Malicious alteration or injection of data to compromise model behavior.

Data Leakage
Unauthorized or improper exposure of held-out or future information to model development.

🧠 Numbered Mind Map · الخريطة الذهنية بالأرقام

Chapter 5
Input Data Testing for Machine Learning Systems
اختبار بيانات الإدخال للتعلم الآلي

- 5.1.1 Input Data Risks and Mitigations
- 5.1.2 Testing for Bias
- 5.1.3 Data Pipeline Testing
- 5.1.4 Testing for Data Representativeness
- 5.1.5 Dataset Constraint Testing
- 5.1.6 Label Correctness Testing
- 5.1.7 Hands-on Exercise: Input Data Testing

الترقيم مبني على فهرس ISTQB CT-AI v2.0 الرسمي، وتلخيص المحتوى أداة تعليمية. راجع الـ Syllabus لكل تفاصيل Learning Objectives والأسئلة الرسمية.