ISTQB CERTIFIED TESTER AI TESTING · VERSION 2.0

ملخصات CT-AI v2.0 | Bilingual Chapter Summaries

عربي + إنجليزي جنب بعض في كل نقطة علمية، مع خريطة ذهنية باللغتين لكل فصل. الهدف فهم المصطلحات، المراجعة الدقيقة، والتطبيق على اختبار AI Interviewer.

Arabic and English, side by side, for each scientific principle, with a bilingual mind map for every chapter. Use these notes to learn terminology, revise accurately, and practice AI Interviewer testing.

ملخصات للمذاكرة وليست نصًا رسميًا من ISTQB. المرجع النهائي للامتحان هو CT-AI v2.0 Official Syllabus. These are study notes, not official ISTQB exam documents.

Chapter 1 | Chapter 2 | Chapter 3 | Chapter 4 | Chapter 5 | Chapter 6 | Chapter 7

Study timetable mapping · ربط الفصول بالجدول

Chapter / الفصل	Scientific focus / المحتوى	Current study days / أيام المذاكرة
Ch 1 — Introduction to Artificial Intelligence	Core principle · AI vs conventional software · AI capability levels	Days 2–3, 11–12
Ch 2 — Quality Characteristics for AI-Based Systems	Core principle · AI-specific characteristics · AI and safety	Days 5, 14–17, 35
Ch 3 — Machine Learning	Forms of machine learning · ML development workflow · Pretrained models, fine-tuning and RAG	Days 2–6, 18–26, 34
Ch 4 — Testing AI-Based Systems	Locked versus adaptive AI · Why statistics matter · The AI test-oracle problem	Days 7–13, 28–30
Ch 5 — Input Data Testing for Machine Learning Systems	Aim of input-data testing · Major data risks · Testing for bias	Days 8–10, 14, 27, 31
Ch 6 — Model Testing for Machine Learning Systems	Why the model itself matters · Documentation review · ML functional performance	Days 13–17, 30–35
Ch 7 — Machine Learning Development Testing	Beyond the model · Development and framework risks · Test approaches	Days 17, 32, 35

Last checked against the bilingual Arabic study summary. The site's live calendar remains authoritative for exact dates and times. Learn → explain → test → collect evidence.

Introduction to Artificial Intelligence

1 الفصل — Introduction to Artificial Intelligence

يؤسس هذا الفصل لغة مشتركة لفهم الذكاء الاصطناعي قبل اختباره: ما الفرق بين النظام التقليدي والنظام المعتمد على الذكاء الاصطناعي، وما أنواع تقنيات AI، وكيف تؤثر البنية التقنية واللوائح على الاختبار.

How AI differs from conventional software, its major forms and technologies, and what these differences mean for testing.

الفكرة المحورية

الأنظمة التقليدية تعمل بقواعد صريحة يكتبها المطوّر، بينما الأنظمة المعتمدة على AI — خاصة أنظمة ML — تتعلم الأنماط من البيانات، لذلك تكون مخرجاتها احتمالية وأقل قابلية للتفسير الكامل. هذا يجعل الاختبار لا يركز فقط على "هل الكود نفّذ المطلوب؟" بل أيضًا "هل التعلّم من البيانات مناسب وآمن ويمكن الوثوق به؟".

Core principle

Conventional software executes explicitly programmed rules. AI-based systems —especially machine-learning systems—learn patterns from data, so their results may be probabilistic and less fully explainable. Testing must establish whether learned behavior is appropriate, reliable, and safe—not merely whether code follows a specification.

AI vs Conventional

النظام التقليدي أكثر حتمية وشفافية وأسهل في تتبع السبب والنتيجة. أما AI فيعتمد على الاستدلال الإحصائي والتعرّف على الأنماط، وقد يقدّم إجابات صحيحة غالبًا لكن ليس دائمًا. لذلك تصبح قابلية التفسير، حدود الخطأ المقبول، والمراقبة المستمرة عناصر أساسية في الجودة.

AI vs conventional software

Traditional rule-based systems are usually more deterministic, traceable, and transparent. AI relies on statistical inference and pattern recognition: it may produce a correct result often, but not always. Explainability, acceptable error boundaries, and monitoring therefore become central to quality.

مستويات AI

Narrow AI هو كل ما نستخدمه اليوم تقريبًا؛ متخصص في مهمة محددة مثل التصنيف أو الترجمة أو التوصية. General AI مفهوم نظري لقدرة عامة شبيهة بالإنسان عبر مهام مختلفة دون إعادة تدريب كبيرة. Super AI تصور يتجاوز الذكاء البشري ويثير مخاطر وجودية وتنظيمية.

AI capability levels

Narrow AI specializes in a limited task, such as classification, translation, or recommendation, and characterizes most deployed applications. Artificial General Intelligence denotes a hypothetical broadly capable system. Super AI describes a hypothetical intelligence beyond human capability, raising major ethical and societal questions.

الأنواع التقنية الأساسية

ML يشمل supervised learning (تصنيف/انحدار)، unsupervised learning (clustering/association)، وreinforcement learning. Deep learning يستخدم شبكات عصبية عميقة مثل CNN للصور، RNN/Transformers للتسلسلات والنصوص. توجد أيضًا NLP وcomputer vision وrule-based systems وfuzzy logic وsearch وagentic AI algorithms.

Main AI techniques

Machine learning includes supervised learning (classification/regression), unsupervised learning (clustering/association), and reinforcement learning. Deep learning uses layered neural networks, including CNNs for imagery and recurrent/Transformer architectures for sequences. Related approaches include NLP, computer vision, rules, fuzzy logic, search, and agentic systems.

Generative AI

يُنشئ نصًا أو صورًا أو صوتًا جديدًا بدل الاكتفاء بالتصنيف. قوته العالية تأتي مع مخاطر مثل hallucination، الحساسية للصياغة، إنتاج محتوى ضار أو غير دقيق، وصعوبة إثبات المصدر. عند الاختبار يجب فحص الفائدة والجودة والسلامة معًا.

Generative AI

Generative AI produces new text, images, or audio rather than merely choosing a label. Its capabilities bring hallucinations, sensitivity to prompts, potentially harmful outputs, and difficulty verifying provenance. Test usefulness, factual quality, and safety together.

البنية التحتية والتطوير

اختيار CPU/GPU/TPU، وقرار cloud vs edge، وأدوات مثل TensorFlow وPyTorch وscikit-learn، كلها تؤثر على الأداء، التكرارية، سهولة النشر، والاختبارات الممكنة. كما أن اللوائح والمعايير التنظيمية تفرض متطلبات تخص الشفافية، السلامة، الخصوصية، والتحكم البشري.

Infrastructure and standards

Hardware (CPU/GPU/TPU), cloud versus edge deployment, and ML frameworks such as TensorFlow, PyTorch, and scikit-learn influence performance, reproducibility, deployment and testability. Standards and regulations add transparency, privacy, safety, and human-control obligations.

Introduction to Artificial Intelligence

بالعربي والإنجليزي — Arabic + English

🧠 الخريطة الذهنية | Bilingual Mind Map

الفصل 1 — خريطة المفاهيم

Chapter 1 · Introduction to Artificial Intelligence

مستويات AI AI capability levels	**AI vs Conventional** AI vs conventional software	**الفكرة المحورية** Core principle
البنية التحتية والتطوير Infrastructure and standards	**Generative AI** Generative AI	**الأنواع التقنية الأساسية** Main AI techniques

نقاط مهمة للاختبار | Exam & practical takeaways

✓ Conventional rules differ from learned and often probabilistic behavior.	✓ AI systems ليست مجرد code rules؛ هي data-driven واحتمالية غالبًا.
✓ Choose tests according to the actual AI capability and technique.	✓ نوع النظام (Narrow/GenAI/Agentic) يغير استراتيجية الاختبار.
✓ Hardware, operating context, and standards influence quality requirements.	✓ العتاد، البيئة، واللوائح ليست تفاصيل جانبية؛ كلها تؤثر على الجودة والاختبار.

🧪 مثال تطبيقي على THL | THL AI Interviewer test idea

Map the interviewer's configured question bank, invitation workflow, recording and evaluation output. Distinguish deterministic API/permission requirements from probabilistic observation quality.

حدّد بنك الأسئلة المجهّز مسبقًا وتدفق الدعوات والتسجيل والتقييم. اختبر قواعد الـ API والصلاحيات بشكل حتمي، وقيّم جودة الـ Observations بمقاييس مناسبة.

⚠️ الاختبارات الاحتمالية تحتاج عينات ومعايير قبول متفق عليها مسبقًا، ومراجعة للنتائج الحرجة. | Statistical AI tests require justified samples, predefined criteria and review of critical outcomes.

Source: ISTQB CT-AI v2.0 · Summary and mind map are bilingual study aids, not verbatim official text.

Quality Characteristics for AI-Based Systems

2 الفصل — Quality Characteristics for AI-Based Systems

Use ISO/IEC 25059 quality characteristics to define measurable, risk-aware acceptance criteria.

يركّز هذا الفصل على ما الذي يعنيه "جودة" في نظام AI وفق ISO/IEC 25059، وكيف تتحول الجودة إلى معايير قبول قابلة للقياس وليست شعارات عامة.

Core principle

AI quality cannot be reduced to conventional functional correctness, because many learned systems inherently make some errors. ISO/IEC 25059 extends the software quality model to capture AI-specific characteristics that inform both testing objectives and acceptance criteria.

الفكرة المحورية

جودة أنظمة AI لا يمكن اختزالها في correctness التقليدية فقط، لأن الخطأ الاحتمالي جزء طبيعي من هذه الأنظمة. لذلك يوسّع ISO/IEC 25059 نموذج الجودة ليشمل خصائص AI-specific تؤثر مباشرة على أهداف الاختبار ومعايير القبول.

AI-specific characteristics

AI functional correctness evaluates correct and incorrect results against accepted error limits. Functional adaptability is the ability to autonomously adapt to operational changes after deployment. User controllability and intervenability concern timely external intervention, the latter specifically in preventing harm. Transparency communicates relevant system information. AI robustness maintains correctness under hostile, biased, invalid, or adverse conditions. Societal and ethical risk mitigation includes fairness, privacy, accountability and human values.

الخصائص النوعية الأساسية

AI functional correctness تعني تقييم المخرجات الصحيحة والخاطئة مع قبول نسب خطأ مضبوطة. Functional adaptability تقيس قدرة النظام على التكيّف بعد النشر. User controllability وintervenability تركّزان على قدرة البشر أو أنظمة أخرى على التدخل في الوقت المناسب. Transparency تعني إتاحة معلومات مفهومة لأصحاب المصلحة. AI robustness تعني بقاء الأداء مقبولًا رغم المدخلات المتحيزة أو المعادية أو الظروف السيئة. Societal and ethical risk mitigation يغطي العدالة والخصوصية والقيم والالتزام المجتمعي.

AI and safety

Safety-related AI faces additional challenges: requirements may begin as vague goals encoded in data; output may be nondeterministic, difficult to explain, or change over time. Functional tests alone are insufficient: evaluate risks, operating boundaries, intervention routes and in-service monitoring.

AI والسلامة

في الأنظمة safety-related يصبح الأمر أصعب لأن المواصفات قد تبدأ كأهداف عامة، والسلوك قد يكون غير حتمي أو صعب التفسير، وقد يتغير مع الزمن. لذلك لا تكفي اختبارات الوظيفة فقط؛ يلزم تحليل مخاطر، حدود تشغيل، مسارات تدخل بشري، ومراقبة تشغيلية.

Measurable AI acceptance criteria

Acceptance criteria must be measurable and tied to risk: approved minimum precision/recall, limits on costly false negatives, acceptable group outcome differences, response times for human intervention, or evidence/explanation requirements. For GenAI, consider groundedness, sensitive-data leakage, harmful-content rates, and compliance with the approved question bank.

معايير القبول AI acceptance criteria

يجب أن تكون قابلة للقياس ومرتبطة بالمخاطر. أمثلة: حد أدنى للدقة/الاستدعاء، حد أقصى للـ false negatives في سياق حساس، نسبة تفاوت مقبولة بين مجموعات سكانية، زمن أقصى للتدخل البشري، أو شرط توفير تفسير/سجل قرار. في GenAI يمكن أن تكون المعايير: groundedness، عدم كشف بيانات حساسة، نسبة منخفضة للمحتوى الضار، أو الالتزام ببنك الأسئلة المعتمد.

Practical quality decisions

The key transition is from saying 'the AI works well' to specifying the critical characteristic, how it is measured, and the agreed pass/fail boundary. Strong AI testing begins with explicit quality objectives and pre-approved acceptance criteria.

الخلاصة العملية

هذا الفصل مهم لأنه يحوّل الحديث من "النظام جيد" إلى "ما هي الخصائص الحرجة؟ كيف نقيسها؟ وما هو حد النجاح/الفشل؟". أي خطة اختبار قوية لأنظمة AI تبدأ من جودة معرّفة بوضوح ومعايير قبول معلنة مسبقًا.

Chapter 2: parallel Arabic / English terminology. Source: ISTQB CT-AI v2.0 syllabus; editorial study summary.

Quality Characteristics for AI-Based Systems

بالعربي والإنجليزي — Arabic + English

🧠 الخريطة الذهنية | Bilingual Mind Map

الفصل 2 — خريطة المفاهيم

Chapter 2 · Quality Characteristics for AI-Based Systems

الفكرة المحورية
Core principle

الخصائص النوعية الأساسية
AI-specific characteristics

AI والسلامة
AI and safety

معايير القبول AI acceptance criteria
Measurable AI acceptance criteria

الخلاصة العملية
Practical quality decisions

نقاط مهمة للاختبار | Exam & practical takeaways

✓ Define which AI-specific qualities matter before choosing tests.	✓ ابدأ من الجودة المطلوبة، لا من عدد test cases فقط.
✓ Set metrics, sample sizes, and risk-based acceptance thresholds in advance.	✓ معايير القبول يجب أن تكون قابلة للقياس ومسبقة الاتفاق.
✓ Transparency, control, and societal safety are consequential qualities.	✓ الشفافية والتحكم البشري والعدالة ليست "nice to have" في الأنظمة الحساسة.

🧪 مثال تطبيقي على THL | THL AI Interviewer test idea

Treat interview Observations as consequential candidate assessments. Require evidence-linked findings, predefined rubric quality metrics, privacy/fairness safeguards and authorized human review before release.

اعتبر الـ Observations نتائج تقييم مؤثرة على المرشح. اربط كل ملاحظة بدليل من الإجابة، وحدد المقاييس والحدود مسبقًا مع مراجعة بشرية مصرح بها عند الحاجة.

⚠️ الاختبارات الاحتمالية تحتاج عينات ومعايير قبول متفق عليها مسبقًا، ومراجعة للنتائج الحرجة. | Statistical AI tests require justified samples, predefined criteria and review of critical outcomes.

Source: ISTQB CT-AI v2.0 · Summary and mind map are bilingual study aids, not verbatim official text.

Machine Learning

3 الفصل — Machine Learning

Understand ML forms, the data-to-model workflow, metrics, pretrained models, RAG and neural networks.

هذا الفصل هو الأساس التقني لفهم دورة حياة ML والبيانات والمقاييس والشبكات العصبية؛ ومن دونه يصعب تفسير نتائج الاختبار أو تشخيص مصدر الخلل.

Forms of machine learning

Supervised learning uses labeled examples to learn classification (discrete classes) or regression (continuous values). Unsupervised learning finds structures in unlabeled data, including clusters and associations. Reinforcement learning uses interaction and reward/penalty feedback. Choose the form according to the task and available data.

أشكال ML

supervised learning يستخدم بيانات مُعلَّمة لمهام classification وregression. unsupervised learning يبحث عن الأنماط دون labels مثل clustering وassociation. reinforcement learning يتعلم عبر التفاعل مع البيئة والمكافآت/العقوبات. اختيار النوع يعتمد على طبيعة البيانات والهدف.

ML development workflow

The typical workflow sets a goal and success criteria, collects and prepares data, separates training/validation/test data, selects features and algorithms, trains and tunes, evaluates, deploys, and monitors. An apparent model defect may originate in an earlier data or feature decision.

الـ workflow القياسي

يبدأ بتحديد الهدف ومعايير النجاح، ثم جمع البيانات وتنظيفها وإعدادها، ثم تقسيمها إلى training/validation/test، ثم اختيار الخوارزمية والخصائص، والتدريب، والضبط، والتقييم، ثم النشر والمراقبة. الفكرة المهمة للاختبار: العيب الظاهر في النموذج قد يكون سببه مرحلة سابقة مثل إعداد البيانات أو اختيار الميزات.

Pretrained models, fine-tuning and RAG

Pretrained models save development effort but inherit limitations and biases. Fine-tuning adapts model parameters to a specialized task. Retrieval-augmented generation (RAG) adds externally retrieved context at inference time rather than permanently teaching new facts; test retrieval relevance and source grounding.

Pretrained models / Fine-tuning / RAG

النماذج الجاهزة تختصر الوقت لكنها تورثك حدودها وانحيازاتها. Fine-tuning يخصص النموذج لمجال معين. RAG لا "يعلم" النموذج حقائق جديدة بقدر ما يزوّده باسترجاع معلومات خارجية وقت التشغيل؛ لذا تصبح جودة الاسترجاع والربط بالمصدر جزءًا من الاختبار.

Data preparation and splits

Preparation covers cleaning, normalization, missing values, feature engineering, class balance, annotation and provenance. Training data fits model parameters; validation data guides tuning; held-out test data supports a less biased final performance estimate. Protect against information leakage between splits.

إعداد البيانات

يشمل تنظيف البيانات، التطبيع، معالجة المفقودات، feature engineering، الموازنة بين الفئات، التسمية/الوسم، وفهم provenance. كما يجب التفريق بين training data لتعلّم النموذج، validation data لضبطه، وtest data للحكم النهائي غير المتحيز.

Classification performance metrics

Given TP, FP, FN and TN, calculate accuracy, precision, recall, specificity and F1. Metric selection depends on impact: a high accuracy can hide poor recall on a minority class, and false positives and false negatives may have very different costs.

مقاييس الأداء للتصنيف

من مصفوفة الالتباس TP/FP/FN/TN نستنتج accuracy وprecision وrecall وspecificity وF1. اختيار المقياس ليس شكليًا؛ في الأنظمة الحساسة قد يكون recall أهم من accuracy، أو قد تكون false positives أكثر تكلفة من false negatives.

Neural networks and coverage

Deep neural networks consist of weighted neurons and activation functions arranged across layers. Learning updates weights to reduce loss. Neuron, neuron-boundary and k-multisection coverage may reveal untested internal behavior but do not by themselves prove accuracy, safety or adequate real-world coverage.

الشبكات العصبية والتغطية

الشبكة العصبية تتكون من neurons وweights وactivations عبر طبقات متعددة. التدريب يضبط الأوزان لتقليل الخطأ. ولأن السلوك الداخلي معقد، توجد مقاييس تغطية مثل neuron coverage وneuron boundary coverage وk-multisection neuron coverage. هذه المقاييس مفيدة استكشافيًا لكنها لا تكفي وحدها لإثبات الجودة أو السلامة.

Chapter 3: parallel Arabic / English terminology. Source: ISTQB CT-AI v2.0 syllabus; editorial study summary.

Machine Learning

بالعربي والإنجليزي — Arabic + English

🧠 الخريطة الذهنية | Bilingual Mind Map

الفصل 3 — خريطة المفاهيم
Chapter 3 · Machine Learning

أشكال ML Forms of machine learning	**الـ workflow القياسي** ML development workflow	**Pretrained models / Fine-tuning / RAG** Pretrained models, fine-tuning and RAG
إعداد البيانات Data preparation and splits	**مقاييس الأداء للتصنيف** Classification performance metrics	**الشبكات العصبية والتغطية** Neural networks and coverage

نقاط مهمة للاختبار | Exam & practical takeaways

✓ Do not confuse train, validation, and independent test datasets.	✓ افهم الفرق بين training/validation/test، لأنه يتكرر في أسئلة كثيرة.
✓ Read the confusion matrix before trusting aggregate accuracy.	✓ اختر metric مناسبًا للمخاطر، وليس الأشهر فقط.
✓ Coverage inside a neural network is not proof of safety or utility.	✓ RAG ليس حلًا سحريًا؛ جودة الاسترجاع نفسها تُختبر.

🧪 مثال تطبيقي على THL | THL AI Interviewer test idea

Build a synthetic candidate_evaluation.csv dataset and compute TP/FP/FN/TN, precision, recall and F1 against independent expert labels. Separately check claim-level observation grounding.

أنشئ ملف candidate_evaluation.csv ببيانات مرشحين صناعية، واحسب TP/FP/FN/TN ثم Precision وRecall وF1 مقابل تقييم خبراء مستقل. وافصل ذلك عن قياس مدى استناد الـ Observations إلى الكلام الفعلي.

$$\text{Precision} = TP/(TP+FP) \quad \cdot \quad \text{Recall} = TP/(TP+FN) \quad \cdot \quad F1 = 2PR/(P+R)$$
$$\text{Accuracy} = (TP+TN)/(TP+TN+FP+FN)$$

⚠️ الاختبارات الاحتمالية تحتاج عينات ومعايير قبول متفق عليها مسبقًا، ومراجعة للنتائج الحرجة. | Statistical AI tests require justified samples, predefined criteria and review of critical outcomes.

Source: ISTQB CT-AI v2.0 · Summary and mind map are bilingual study aids, not verbatim official text.

Testing AI-Based Systems

4 الفصل — Testing AI-Based Systems

يشرح هذا الفصل لماذا يختلف اختبار AI عن اختبار البرمجيات التقليدية، ولماذا نحتاج إلى منهج إحصائي واختبارات استكشافية وحلول بديلة لمشكلة الـ oracle.

Select AI-appropriate oracles, statistical testing, GenAI exploration, red teaming and risk-based test levels.

Locked vs Adaptive

النظام locked لا يغير سلوكه بعد النشر، لذا اختباره أسهل نسبيًا ويشبه إصدارًا ثابتًا. أما adaptive system فيتعلّم أو يتكيّف بعد النشر، لذلك قد يتغير سلوكه أثناء التشغيل، ويصعب التنبؤ بكل الحالات مسبقًا. كثير من أنظمة LLM تقع بين الاثنين: النموذج locked وقت التشغيل، لكن يتم تحديثه دوريًا.

Locked versus adaptive AI

A locked AI model does not intentionally update its learned behavior after deployment and is easier to retest as a fixed version. An adaptive model changes during operation, making unseen behaviors possible. Many LLM applications use a locked model at runtime but periodically release updated versions; each change needs regression evidence.

لماذا المنهج الإحصائي؟

لأن كثيرًا من أنظمة AI تعمل احتماليًا، فلا يكفي اختبار حالة واحدة بحكم deterministic. نحتاج عينات ممثلة، توزيع أداء، حدود ثقة، ونسب نجاح/فشل عبر فئات وسيناريوهات مختلفة. القبول هنا لا يُبنى على "خرج مطابق مرة واحدة" بل على أداء مقبول ومتكرر عبر نطاق مناسب.

Why statistics matter

Because learned outputs can be probabilistic, one passing deterministic example rarely establishes quality. Evaluate representative samples, distributions, confidence/uncertainty and error rates across relevant scenarios, then compare them with pre-agreed thresholds.

مشكلة test oracle

في البرمجيات التقليدية تكون النتيجة المتوقعة غالبًا واضحة من المواصفات. أما في AI فقد تكون الحقيقة الأرضية غير مكتملة أو ذاتية أو فوق قدرة الإنسان. الحلول تشمل: استخدام ground truth، خبراء المجال، التقييم الإحصائي، المقارنة بنظام آخر، أو العلاقات metamorphic.

The AI test-oracle problem

The test-oracle problem arises when a single unambiguously correct output is unavailable. AI tasks may be subjective, fuzzy or beyond reliable human scoring. Use expert judgment, verified ground truth, statistical comparisons, back-to-back or metamorphic relations as suitable oracles.

اختبار GenAI وLLM

لا يقتصر على الوظيفة، بل يشمل groundedness، factuality، الالتزام بالتعليمات، السلامة، مقاومة jailbreak/prompt injection، الثبات النسبي، استخدام الأدوات أو الاسترجاع، وأثر صياغة prompts. exploratory testing مهم هنا لأنه يكشف سلوكيات غير متوقعة بسرعة.

Testing GenAI and LLMs

Test generative AI for factual accuracy, evidence grounding, instruction following, safety, jailbreak/prompt-injection resistance, stability and tool/retrieval behavior. Exploratory testing probes unexpected behavior and prompt sensitivity.

Red teaming

أسلوب هجومي منظم لاكتشاف نقاط الضعف وسوء الاستخدام والثغرات الأمنية أو الأخلاقية. الغرض ليس مجرد "كسر النظام"، بل اختبار حدود الحماية والضوابط وماذا يحدث تحت الضغط أو الاستخدام العدائي.

Red teaming

Red teaming systematically challenges misuse boundaries, vulnerabilities and harmful behavior. The goal is to reveal weaknesses and confirm protections under adversarial inputs, not simply to make the model give a surprising answer.

Test levels وRisk-based testing

في أنظمة ML نختبر البيانات، النموذج، pipeline، التكامل، النظام ككل، والقبول والنشر. وتحديد الأولويات يجب أن يبنى على المخاطر: أين يمكن أن يسبب الخطأ ضررًا أكبر؟ ما السيناريوهات الحرجة؟ ما الذي يحتاج أعمق قدر من الأدلة؟

Test levels and risk-based testing

ML testing covers input data, the model and pipeline, integration, system and acceptance, and deployment. Allocate more effort to high-severity and high-likelihood failures—for example, incorrect candidate evaluation or unauthorized data access.

Chapter 4: parallel Arabic / English terminology. Source: ISTQB CT-AI v2.0 syllabus; editorial study summary.

Testing AI-Based Systems

بالعربي والإنجليزي — Arabic + English

🧠 الخريطة الذهنية | Bilingual Mind Map

الفصل 4 — خريطة المفاهيم

Chapter 4 · Testing AI-Based Systems

test oracle مشكلة The AI test-oracle problem	**لماذا المنهج الإحصائي؟** Why statistics matter	**Locked vs Adaptive** Locked versus adaptive AI
Risk-based testing و Test levels Test levels and risk-based testing	**Red teaming** Red teaming	**اختبار GenAI وLLM** Testing GenAI and LLMs

نقاط مهمة للاختبار | Exam & practical takeaways

✓ A single plausible LLM answer is not a sufficient test result.	✓ المعيار الإحصائي مهم لأن المخرجات قد لا تكون حتمية.
✓ Pick an appropriate oracle and test statistically where needed.	✓ الـ oracle problem من أهم خصائص اختبار AI.
✓ Prioritize severe AI harms and abuse cases.	✓ LLM testing = جودة + سلامة + مقاومة إساءة الاستخدام.

🧪 مثال تطبيقي على THL | THL AI Interviewer test idea

Use deterministic assertions for permissions and saved questions; expert goldens for candidate Observations; repeated runs, prompt injection and transcript/video evidence for model quality.

اختبر الصلاحيات والالتزام ببنك الأسئلة بـ assertions حتمية، واستخدم Golden Answers مستقلة لـ Observations، وكرّر التشغيل واختبر Prompt Injection والربط بالتسجيل.

⚠️ الاختبارات الاحتمالية تحتاج عينات ومعايير قبول متفق عليها مسبقًا، ومراجعة للنتائج الحرجة. | Statistical AI tests require justified samples, predefined criteria and review of critical outcomes.

Source: ISTQB CT-AI v2.0 · Summary and mind map are bilingual study aids, not verbatim official text.

Input Data Testing for Machine Learning Systems

5 الفصل — Input Data Testing for Machine Learning Systems

هذا الفصل يرسّخ المبدأ الحاسم في ML: جودة البيانات ليست خطوة تمهيدية فقط، بل هي جزء مباشر من جودة النظام نفسه.

Verify provenance, pipeline integrity, bias, representativeness, constraints and labels.

الهدف العام

التأكد من أن البيانات المستخدمة للتدريب أو التقييم أو التنبؤ ذات جودة كافية. أي خلل في البيانات — provenance أو تمثيل أو labels أو pipeline — قد يظهر لاحقًا كخلل في "ذكاء" النظام، رغم أن أصل المشكلة بيانات وليس نموذجًا.

Aim of input-data testing

Verify that data used for training, evaluation and inference meets quality requirements. Errors in provenance, labels, representation or pipelines can look like model failures even when the model implementation itself is sound.

المخاطر الرئيسية

التحيز، poisoning، مصادر غير موثوقة، عدم الاتساق، قيم خارج المدى، أنواع خاطئة، نقص التمثيل، missing data، skewed distributions، وضعف إرشادات الوسم. كل خطر يقابله أسلوب تخفيف/اختبار مناسب مثل provenance testing أو EDA أو dataset constraint testing أو label correctness testing.

Major data risks

Key risks include bias, poisoning, untrusted sources, inconsistency, out-of-range values, wrong types, underrepresented groups, skewed distributions, missing fields and unclear labeling guidelines. Use provenance checks, EDA, constraint testing and label reviews to mitigate the corresponding risks.

Testing for bias

التحيز قد يأتي من البيانات (historical skew, unrepresentative data, poisoned data) أو من الخوارزمية/العتبات. أساليب الكشف تشمل مراجعة workflow، مراجعة توثيق البيانات، static analysis، التحليل الاستكشافي للبيانات، واختبارات المقارنة بين المجموعات الحساسة مثل disparate impact analysis.

Testing for bias

Bias can originate in historical data, unrepresentative collection, manipulation, algorithms or thresholds. Review processes and documentation, analyze subgroup data, and compare relevant groups—for example via disparate-impact assessment—with suitable risk and statistical context.

Data pipeline testing

يختبر استخراج البيانات وتحويلها وتحميلها، سلامة الـ schema، missing values، التكرار، الأداء، الأمان، وجودة المخرجات بعد كل مرحلة. أي خطأ في pipeline قد يشوّه features أو labels أو يغرس تحيزًا غير مقصود.

Data-pipeline testing

Test each stage of extraction, transformation and loading: schema, completeness, duplicates, missing values, performance, security and transformed values. A pipeline error can silently alter features or labels and introduce systematic bias.

Representativeness & constraints

يجب أن تمثل البيانات السكان، السيناريوهات، الفئات، ونطاق القيم المتوقع تشغيل النظام عليها. كما يجب اختبار القيود مثل نوع الحقول، الحدود المسموح بها، قواعد الاتساق والاكتمال. هنا نمنع "garbage in" قبل أن يصبح "garbage out".

Representativeness and constraints

Datasets should reflect intended operational cases, populations, classes and valid value ranges. Assert types, bounds, consistency and completeness and investigate underrepresented scenarios before accepting a benchmark or model.

Label correctness

إذا كانت labels خاطئة أو غير متسقة فلن يكون "التعلّم" صحيحًا مهما كانت الخوارزمية جيدة. لذلك يلزم إرشادات وسم واضحة، multiple annotation عند الحاجة، آلية adjudication، وقياس الاتفاق بين المعلِّقين. في أنظمة التقييم والمقابلات، استقلال الـ SME goldens عن مخرجات النموذج أمر أساسي.

Label correctness

Incorrect or inconsistent labels undermine the learned target. Set clear annotation guidelines, use multiple annotators as appropriate, adjudicate disagreements and check inter-annotator consistency. Golden candidate labels should be established independently of the model outputs.

Chapter 5: parallel Arabic / English terminology. Source: ISTQB CT-AI v2.0 syllabus; editorial study summary.

Input Data Testing for Machine Learning Systems

بالعربي والإنجليزي — Arabic + English

🧠 الخريطة الذهنية | Bilingual Mind Map

الفصل 5 — خريطة المفاهيم

Chapter 5 · Input Data Testing for Machine Learning Systems

الهدف العام Aim of input-data testing	**المخاطر الرئيسية** Major data risks	**Testing for bias** Testing for bias
Data pipeline testing Data-pipeline testing	**Representativeness & constraints** Representativeness and constraints	**Label correctness** Label correctness

نقاط مهمة للاختبار | Exam & practical takeaways

✓ A good model cannot rescue invalid or unrepresentative data by itself.	✓ معظم مشاكل "الذكاء" قد يكون أصلها البيانات.
✓ Test the pipeline, not just the final CSV.	✓ bias وrepresentativeness وlabels ثلاثي حاسم.
✓ Independent and consistently labeled goldens make evaluation credible.	✓ اختبر pipeline لا البيانات الساكنة فقط.

🧪 مثال تطبيقي على THL | THL AI Interviewer test idea

Check candidate answer datasets for missing recordings, incomplete transcripts, duplicated questions, imbalanced languages, leaked identifiers and expert-label disagreements.

اختبر بيانات إجابات المرشحين ضد غياب التسجيلات، نقص الـ Transcript، تكرار الأسئلة، عدم توازن اللغات، تسريب البيانات، واختلاف تقييمات الخبراء.

⚠️ Statistical AI tests require justified samples, predefined criteria and review of critical outcomes. | الاختبارات الاحتمالية تحتاج عينات ومعايير قبول متفق عليها مسبقًا، ومراجعة للنتائج الحرجة.

Source: ISTQB CT-AI v2.0 · Summary and mind map are bilingual study aids, not verbatim official text.

Model Testing for Machine Learning Systems

6 الفصل — Model Testing for Machine Learning Systems

يختص هذا الفصل باختبار النموذج نفسه: الأداء، المتانة، الانجراف، الإفراط أو القصور في التعلّم، والتأكد من أن التحديثات لا تضرّ بالنظام.

Test model performance and robustness, metamorphic relations, adversarial behavior and drift.

نطاق الفصل

لا يكفي أن تكون البيانات جيدة؛ النموذج نفسه قد يكون متحيزًا أو هشًّا أو overfitted أو underfitted أو ضعيف الأداء. لذلك نحتاج استراتيجيات اختبار مخصصة للنماذج الاحتمالية، مع قياسات وظيفية وغير وظيفية.

Why the model itself matters

Clean data alone does not guarantee a sound model. A trained model may be biased, fragile, overfitted, underfitted or weak on important cases. Model testing needs functional and nonfunctional quality evidence.

مراجعة التوثيق

مراجعة model documentation تكشف أمورًا حاسمة: الهدف المقصود، الحدود، بيانات التدريب، المقاييس، الافتراضات، القيود، واجهات الاستخدام، وknown limitations. التوثيق الجيد شرط مهم للشفافية، إعادة الاختبار، والتفسير الصحيح للنتائج.

Documentation review

Review model purpose, assumptions, training context, interfaces, performance definitions, evaluation evidence, known limitations and operating constraints. Documentation enables correct interpretation, traceability, explanation and repeatable testing.

ML functional performance testing

يتم غالبًا على بيانات holdout أو test data مستقلة، مع حساب مقاييس مرتبطة بالمخاطر مثل precision/recall/F1. في الأنظمة الاحتمالية لا يكفي إعلان "الدقة 90%" دون فهم التوزيع والفئات التي يفشل فيها النموذج وتكلفة أنواع الأخطاء المختلفة.

ML functional performance

Evaluate an independent holdout with risk-appropriate metrics such as precision, recall and F1. An overall figure like 90% accuracy is inadequate without analyzing subgroups, false-error types and their different costs.

Adversarial testing

يختبر حساسية النموذج لمدخلات مصممة لخداعه أو تقليل أدائه. هذا مهم للأمن والسلامة وAI robustness. الهجوم قد يكون بسيطًا في الصياغة أو perturbation صغيرًا لكنه يؤدي إلى نتيجة خاطئة تمامًا.

Adversarial testing

Adversarial tests intentionally perturb or manipulate input to mislead the model and reveal robustness, security or safety weaknesses. Small input modifications can cause disproportionately incorrect outputs.

Metamorphic testing

مهم عندما يصعب تحديد expected result بدقة. بدلًا من ذلك نعرّف علاقة يجب أن تبقى صحيحة بين مخرجات مدخلات مرتبطة. مثال: إعادة صياغة إجابة مرشح بنفس المعنى لا ينبغي أن تقلب الحكم جذريًا. هذا أسلوب قوي لحل جزء من مشكلة الـ oracle.

Metamorphic testing

Where an exact target answer is difficult to specify, define a relation between linked inputs and outputs that should remain valid. A meaning-preserving rephrasing of a candidate answer should not abruptly reverse the competency assessment.

Drift / overfitting / underfitting / A/B / back-to-back

drift testing يراقب تغير البيانات أو المفهوم التشغيلي بمرور الزمن. overfitting يظهر عندما يحفظ النموذج بيانات التدريب ويفشل على البيانات الجديدة، بينما underfitting يعني أن النموذج لم يتعلم بما يكفي. A/B testing يقارن نسختين في التشغيل، وback-to-back testing يقارن ناتج النسخة الجديدة بالقديمة أو بمرجع آخر لكشف regression أو تراجع الأداء.

Drift, over/underfitting and comparisons

Drift checks changes in data or operating relationships over time. Overfitting captures training examples but generalizes poorly; underfitting fails to learn enough structure. A/B compares versions under controlled conditions; back-to-back compares new and previous/reference results to detect regression.

Model Testing for Machine Learning Systems

بالعربي والإنجليزي — Arabic + English

🧠 الخريطة الذهنية | Bilingual Mind Map

الفصل 6 — خريطة المفاهيم

Chapter 6 · Model Testing for Machine Learning Systems

نطاق الفصل Why the model itself matters	**مراجعة التوثيق** Documentation review	**ML functional performance testing** ML functional performance
Adversarial testing Adversarial testing	**Metamorphic testing** Metamorphic testing	**-Drift / overfitting / underfitting / A/B / back-to back** Drift, over/underfitting and comparisons

نقاط مهمة للاختبار | Exam & practical takeaways

✓ Evaluate errors per segment and risk, not just headline accuracy.	✓ المقارنة بين النسخ وإدارة drift لا تقل أهمية عن دقة النموذج الحالية.
✓ Metamorphic relations help test models without a perfect oracle.	✓ metamorphic testing سلاح قوي عندما يصعب تحديد expected result.
✓ Retest under drift, version changes and adversarial inputs.	✓ راجع التوثيق؛ الوثائق السيئة تفسد الفهم والحكم على النتائج.

🧪 مثال تطبيقي على THL | THL AI Interviewer test idea

Evaluate semantic paraphrases, Arabic/English equivalents and speech-noise variants against the same rubric; compare old/new report models and track harmful observation errors.

قارن إعادة صياغة الإجابات المكافئة بالعربي والإنجليزي ونسخ الصوت المشوشة تحت نفس الـ Rubric، واختبر اختلاف نتائج نسخ النموذج بدون اختراع خبرات للمرشح.

⚠️ الاختبارات الاحتمالية تحتاج عينات ومعايير قبول متفق عليها مسبقًا، ومراجعة للنتائج الحرجة. | Statistical AI tests require justified samples, predefined criteria and review of critical outcomes.

Source: ISTQB CT-AI v2.0 · Summary and mind map are bilingual study aids, not verbatim official text.

Machine Learning Development Testing

7 الفصل — Machine Learning Development Testing

Assure frameworks, builds, deployment environments and production rollout beyond the model weights.

الفصل الأخير يحوّل التركيز من "النموذج" إلى "بيئة التطوير والنشر": الأدوات، الأطر، الإعدادات، وعمليات الإصدار التي قد تُدخل مخاطر جديدة.

Beyond the model

A reliable model can still fail because of incorrect framework calls, API misuse, build defects, data-splitting mistakes or faulty deployment. The ML development and delivery lifecycle must be tested as a system.

الفكرة المحورية

قد يفشل النظام حتى لو كان النموذج جيدًا، بسبب خطأ في framework، سوء استخدام API، build defect، تقسيم غير صحيح للبيانات، أو مشكلة في النشر على البيئة المستهدفة. لذلك يجب اختبار دورة التطوير والنشر نفسها.

Development and framework risks

Risks include wrong TensorFlow/PyTorch API usage, unsuitable framework or algorithm selection, misconfigured hyperparameters, installation/build failures, incorrect metric implementation, stochastic training misinterpretation and insecure dependencies.

مخاطر التطوير

تشمل الاستخدام الخاطئ لمكتبات مثل TensorFlow/PyTorch، اختيار framework أو algorithm غير مناسب، hyperparameters دون ضبط جيد، عيوب في التثبيت والبناء، أخطاء في تنفيذ التقييم داخل الأداة، سوء تفسير النتائج بسبب stochastic training، أو ثغرات أمنية في المكتبات.

Test approaches

Mitigations include API and smoke tests, framework/documentation reviews, performance, usability and security checks, cross-checks of results, back-to-back comparisons and A/B tests. These validate the engineering lifecycle, not only AI accuracy.

وسائل التخفيف والاختبار

API testing، smoke testing، framework/documentation reviews، performance testing، usability testing، security testing، cross-checking results، back-to-back testing، وA/B testing. هذه الأساليب لا تختبر "الذكاء" فقط، بل صحة خط التطوير نفسه.

Deployment testing

Deployment tests cover installation, configuration, uninstallability as appropriate, target-environment compatibility (cloud, edge, mobile), drivers and dependencies, APIs, performance and operational behavior. Laboratory success does not guarantee deployment safety.

Deployment testing

عند نشر MLS يجب اختبار قابلية التثبيت والتهيئة والإزالة، التوافق مع البيئة (cloud, edge, mobile)، الاعتماديات مثل interfaces/APIs، GPU drivers، الأداء، والأثر الفعلي بعد النشر. الفكرة ليست أن النموذج يعمل في المختبر فقط، بل أن يعمل بأمان في الواقع.

Shadow testing and release practices

Shadow testing runs a proposed model against real-world inputs without allowing it to control the production decision, enabling safer comparison before release. Smoke, regression and A/B checks also support version changes and controlled rollout.

Shadow testing وغيرها

shadow testing يسمح بمراقبة نموذج جديد في بيئة تشغيل حقيقية دون أن يتحكم فعليًا في المخرجات، ما يقدّم دليلًا عالي القيمة قبل التبديل الكامل. كما تُستخدم اختبارات smoke وregression وA/B عند التحديثات.

End-to-end quality chain

Trustworthy AI quality spans data, trained model, framework, pipeline, deployment and monitoring. Chapter 7 ensures that results from earlier testing are not lost during integration and release.

الخلاصة العملية

جودة AI ليست "ملف model.pkl جيد". هي سلسلة كاملة: بيانات، نموذج، framework، pipeline، deployment، monitoring. الفصل 7 يضمن ألا تضيع جودة المراحل السابقة عند الانتقال من التطوير إلى التشغيل.

Machine Learning Development Testing

بالعربي والإنجليزي — Arabic + English

🧠 الخريطة الذهنية | Bilingual Mind Map

الفصل 7 — خريطة المفاهيم

Chapter 7 · Machine Learning Development Testing

الفكرة المحورية Beyond the model	**مخاطر التطوير** Development and framework risks	**وسائل التخفيف والاختبار** Test approaches
Deployment testing Deployment testing	**Shadow testing وغيرها** Shadow testing and release practices	**الخلاصة العملية** End-to-end quality chain

نقاط مهمة للاختبار | Exam & practical takeaways

✓ Test the ML toolchain and target environment, not only predictions.	✓ جودة ML pipeline والتطوير والنشر تساوي أهمية جودة النموذج نفسه.
✓ Version changes require controlled comparison and regression evidence.	✓ اختبر التوافق، التثبيت، الأداء، الأمان، وshadow deployment.
✓ Safe release requires both model quality and operational reliability.	✓ التحسين في المختبر لا يكفي؛ يجب إثبات التحسن في البيئة المستهدفة.

🧪 مثال تطبيقي على THL | THL AI Interviewer test idea

Run deployment smoke/API checks, compare reports in shadow mode where supported, verify tenant isolation and retain model, prompt, rubric and evaluation version evidence.

نفّذ Smoke/API tests على بيئة النشر، وقارن نتائج التقارير بنمط Shadow إن كان مدعومًا، وراجع عزل المؤسسات ووثّق نسخة النموذج والـ Prompt والـ Rubric والتقييم.

⚠️ الاختبارات الاحتمالية تحتاج عينات ومعايير قبول متفق عليها مسبقًا، ومراجعة للنتائج الحرجة. | Statistical AI tests require justified samples, predefined criteria and review of critical outcomes.

Source: ISTQB CT-AI v2.0 · Summary and mind map are bilingual study aids, not verbatim official text.