الفصل 4 — Testing AI-Based Systems

الفكرة العامة: يشرح هذا الفصل لماذا يختلف اختبار AI عن اختبار البرمجيات التقليدية، ولماذا نحتاج إلى منهج إحصائي واختبارات استكشافية وحلول بديلة لمشكلة الـ oracle.

الخريطة الذهنية

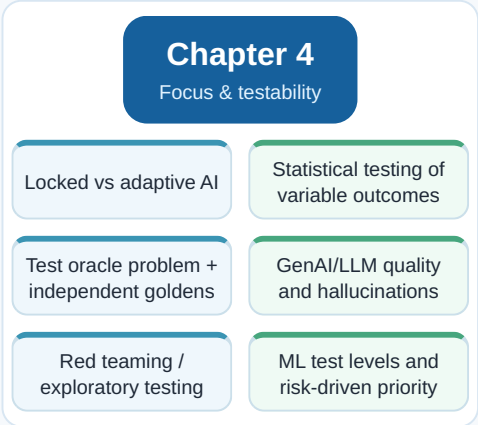

خريطة ذهنية سريعة للمراجعة قبل التطبيق أو قبل حل الأسئلة.

الملخص المركز

- **Locked vs Adaptive:** النظام locked لا يغير سلوكه بعد النشر، لذا اختباره أسهل نسبيًا ويشبه إصدارًا ثابتًا. أما adaptive system فيتعلّم أو يتكيّف بعد النشر، لذلك قد يتغير سلوكه أثناء التشغيل، ويصعب التنبؤ بكل الحالات مسبقًا. كثير من أنظمة LLM تقع بين الاثنين: النموذج locked وقت التشغيل، لكن يتم تحديثه دوريًا.
- **لماذا المنهج الإحصائي؟** لأن كثيرًا من أنظمة AI تعمل احتماليًا، فلا يكفي اختبار حالة واحدة بحكم deterministic. نحتاج عينات ممثلة، توزيع أداء، حدود ثقة، ونسب نجاح/فشل عبر فئات وسيناريوهات مختلفة. القبول هنا لا يُبنى على "خرج مطابق مرة واحدة" بل على أداء مقبول ومتكرر عبر نطاق مناسب.
- **مشكلة test oracle:** في البرمجيات التقليدية تكون النتيجة المتوقعة غالبًا واضحة من المواصفات. أما في AI فقد تكون الحقيقة الأرضية غير مكتملة أو ذاتية أو فوق قدرة الإنسان. الحلول تشمل: استخدام ground truth، خبراء المجال، التقييم الإحصائي، المقارنة بنظام آخر، أو العلاقات metamorphic.
- **اختبار GenAI وLLM:** لا يقتصر على الوظيفة، بل يشمل factuality، groundedness، الالتزام بالتعليمات، السلامة، مقاومة jailbreak/prompt injection، الثبات النسبي، استخدام الأدوات أو الاسترجاع، وأثر

صياغة prompts. exploratory testing مهم هنا لأنه يكشف سلوكيات غير متوقعة بسرعة.

- **Red teaming:** أسلوب هجومي منظم لاكتشاف نقاط الضعف وسوء الاستخدام والثغرات الأمنية أو الأخلاقية. الغرض ليس مجرد "كسر النظام"، بل اختبار حدود الحماية والضوابط وماذا يحدث تحت الضغط أو الاستخدام العدائي.
- **Test levels وRisk-based testing:** في أنظمة ML نختبر البيانات، النموذج، pipeline، التكامل، النظام ككل، والقبول والنشر. وتحديد الأولويات يجب أن يبنى على المخاطر: أين يمكن أن يسبب الخطأ ضررًا أكبر؟ ما السيناريوهات الحرجة؟ ما الذي يحتاج أعمق قدر من الأدلة؟

ما الذي يجب تذكره في الاختبار والعمل؟

- المعيار الإحصائي مهم لأن المخرجات قد لا تكون حتمية.
- الـ oracle problem من أهم خصائص اختبار AI.
- LLM testing = جودة + سلامة + مقاومة إساءة الاستخدام.