الفصل 5 — Input Data Testing for Machine Learning Systems

الفكرة العامة: هذا الفصل يرسّخ المبدأ الحاسم في ML: جودة البيانات ليست خطوة تمهيدية فقط، بل هي جزء مباشر من جودة النظام نفسه.

الخريطة الذهنية

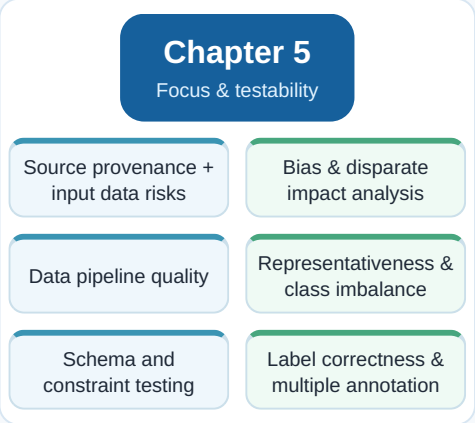

خريطة ذهنية سريعة للمراجعة قبل التطبيق أو قبل حل الأسئلة.

الملخص المركز

- **الهدف العام:** التأكد من أن البيانات المستخدمة للتدريب أو التقييم أو التنبؤ ذات جودة كافية. أي خلل في البيانات — provenance أو تمثيل أو labels أو pipeline — قد يظهر لاحقًا كخلل في "ذكاء" النظام، رغم أن أصل المشكلة بيانات وليس نموذجًا.
- **المخاطر الرئيسية:** التحيز، poisoning، مصادر غير موثوقة، عدم الاتساق، قيم خارج المدى، أنواع خاطئة، نقص التمثيل، skewed distributions، missing data، وضعف إرشادات الوسم. كل خطر يقابله أسلوب تخفيف/اختبار مناسب مثل provenance أو EDA أو dataset constraint testing أو label correctness testing.
- **Testing for bias:** التحيز قد يأتي من البيانات (historical skew, unrepresentative data, poisoned data) أو من الخوارزمية/العتبات. أساليب الكشف تشمل مراجعة workflow، مراجعة توثيق البيانات، static analysis، التحليل الاستكشافي للبيانات، واختبارات المقارنة بين المجموعات الحساسة مثل disparate impact analysis.
- **Data pipeline testing:** يختبر استخراج البيانات وتحويلها وتحميلها، سلامة الـ schema، missing values، التكرار، الأداء، الأمان، وجودة المخرجات بعد كل مرحلة. أي خطأ في pipeline قد يشوّه features أو labels أو يغرس تحيزًا غير مقصود.

- **Representativeness & constraints:** يجب أن تمثل البيانات السكان، السيناريوهات، الفئات، ونطاق القيم المتوقع تشغيل النظام عليها. كما يجب اختبار القيود مثل نوع الحقول، الحدود المسموح بها، قواعد الاتساق والاكتمال. هنا نمنع "garbage in" قبل أن يصبح "garbage out".
- **Label correctness:** إذا كانت labels خاطئة أو غير متسقة فلن يكون "التعلّم" صحيحًا مهما كانت الخوارزمية جيدة. لذلك يلزم إرشادات وسم واضحة، multiple annotation عند الحاجة، آلية adjudication، وقياس الاتفاق بين المعلِّقين. في أنظمة التقييم والمقابلات، استقلال الـ SME goldens عن مخرجات النموذج أمر أساسي.

ما الذي يجب تذكره في الاختبار والعمل؟

- معظم مشاكل "الذكاء" قد يكون أصلها البيانات.
- bias وrepresentativeness وlabels ثلاثي حاسم.
- اختبر pipeline لا البيانات الساكنة فقط.