الفصل 6 — Model Testing for Machine Learning Systems

الفكرة العامة: يختص هذا الفصل باختبار النموذج نفسه: الأداء، المتانة، الانجراف، الإفراط أو القصور في التعلّم، والتأكد من أن التحديثات لا تضرّ بالنظام.

الخريطة الذهنية

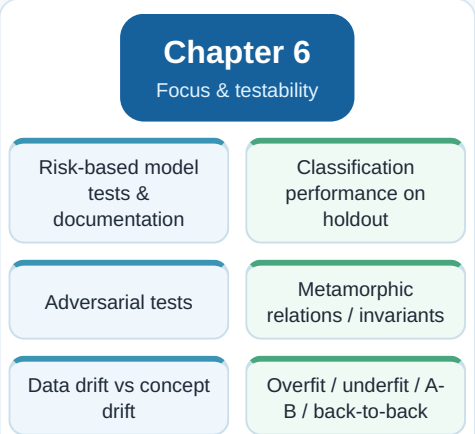

خريطة ذهنية سريعة للمراجعة قبل التطبيق أو قبل حل الأسئلة.

الملخص المركز

- **نطاق الفصل:** لا يكفي أن تكون البيانات جيدة؛ النموذج نفسه قد يكون متحيزًا أو هشًا أو overfitted أو underfitted أو ضعيف الأداء. لذلك نحتاج استراتيجيات اختبار مخصصة للنماذج الاحتمالية، مع قياسات وظيفية وغير وظيفية.
- **مراجعة التوثيق:** مراجعة model documentation تكشف أمورًا حاسمة: الهدف المقصود، الحدود، بيانات التدريب، المقاييس، الافتراضات، القيود، واجهات الاستخدام، وknown limitations. التوثيق الجيد شرط مهم للشفافية، إعادة الاختبار، والتفسير الصحيح للنتائج.
- **ML functional performance testing:** يتم غالبًا على بيانات holdout أو test data مستقلة، مع حساب مقاييس مرتبطة بالمخاطر مثل precision/recall/F1. في الأنظمة الاحتمالية لا يكفي إعلان "الدقة 90%" دون فهم التوزيع والفئات التي يفشل فيها النموذج وتكلفة أنواع الأخطاء المختلفة.
- **Adversarial testing:** يختبر حساسية النموذج لمدخلات مصممة لخداعه أو تقليل أدائه. هذا مهم للأمن والسلامة وAI robustness. الهجوم قد يكون بسيطًا في الصياغة أو perturbation صغيرًا لكنه يؤدي إلى نتيجة خاطئة تمامًا.
- **Metamorphic testing:** مهم عندما يصعب تحديد expected result بدقة. بدلًا من ذلك

نعرّف علاقة يجب أن تبقى صحيحة بين مخرجات مدخلات مرتبطة. مثال: إعادة صياغة إجابة مرشح بنفس المعنى لا ينبغي أن تقلب الحكم جذريًا. هذا أسلوب قوي لحل جزء من مشكلة الـ oracle.

- **/ Drift / overfitting / underfitting / A/B back-to-back:** drift testing يراقب تغير البيانات أو المفهوم التشغيلي بمرور الزمن. overfitting يظهر عندما يحفظ النموذج بيانات التدريب ويفشل على البيانات الجديدة، بينما underfitting يعني أن النموذج لم يتعلم بما يكفي. A/B testing يقارن نسختين في التشغيل، وback-to-back testing يقارن ناتج النسخة الجديدة بالقديمة أو بمرجع آخر لكشف regression أو تراجع الأداء.

ما الذي يجب تذكره في الاختبار والعمل؟

- المقارنة بين النسخ وإدارة drift لا تقل أهمية عن دقة النموذج الحالية.
- metamorphic testing سلاح قوي عندما يصعب تحديد expected result.
- راجع التوثيق؛ الوثائق السيئة تفسد الفهم والحكم على النتائج.