الفصل 7 — Machine Learning Development Testing

الفكرة العامة: الفصل الأخير يحوّل التركيز من "النموذج" إلى "بيئة التطوير والنشر": الأدوات، الأطر، الإعدادات، وعمليات الإصدار التي قد تُدخل مخاطر جديدة.

الخريطة الذهنية

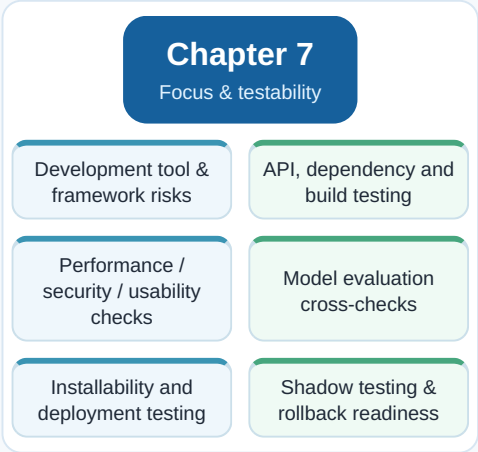

خريطة ذهنية سريعة للمراجعة قبل التطبيق أو قبل حل الأسئلة.

الملخص المركز

- **الفكرة المحورية:** قد يفشل النظام حتى لو كان النموذج جيدًا، بسبب خطأ في framework، سوء استخدام API، build defect، تقسيم غير صحيح للبيانات، أو مشكلة في النشر على البيئة المستهدفة. لذلك يجب اختبار دورة التطوير والنشر نفسها.
- **مخاطر التطوير:** تشمل الاستخدام الخاطئ لمكتبات مثل TensorFlow/PyTorch، اختيار framework أو algorithm غير مناسب، hyperparameters دون ضبط جيد، عيوب في التثبيت والبناء، أخطاء في تنفيذ التقييم داخل الأداة، سوء تفسير النتائج بسبب stochastic training، أو ثغرات أمنية في المكتبات.
- **وسائل التخفيف والاختبار:** API testing، smoke testing، framework/documentation reviews، performance testing، usability testing، security testing، cross-checking results، back-to-back testing، وA/B testing. هذه الأساليب لا تختبر "الذكاء" فقط، بل صحة خط التطوير نفسه.
- **Deployment testing:** عند نشر MLS يجب اختبار قابلية التثبيت والتهيئة والإزالة، التوافق مع البيئة (cloud, edge, mobile)، الاعتماديات مثل interfaces/APIs، GPU drivers، الأداء، والأثر الفعلي بعد النشر. الفكرة ليست أن النموذج يعمل في المختبر فقط، بل أن يعمل بأمان في الواقع.

- **Shadow testing وغيرها:** shadow testing يسمح بمراقبة نموذج جديد في بيئة تشغيل حقيقية دون أن يتحكم فعليًا في المخرجات، ما يقدّم دليلًا عالي القيمة قبل التبديل الكامل. كما تُستخدم اختبارات smoke وregression وA/B عند التحديثات.
- **الخلاصة العملية:** جودة AI ليست "ملف model.pkl جيد". هي سلسلة كاملة: بيانات، نموذج، deployment، pipeline، framework، monitoring. الفصل 7 يضمن ألا تضيع جودة المراحل السابقة عند الانتقال من التطوير إلى التشغيل.

ما الذي يجب تذكره في الاختبار والعمل؟

- جودة ML pipeline والتطوير والنشر تساوي أهمية جودة النموذج نفسه.
- اختبر التوافق، التثبيت، الأداء، الأمان، وshadow deployment.
- التحسين في المختبر لا يكفي؛ يجب إثبات التحسن في البيئة المستهدفة.