ملخصات فصول Syllabus — Certified Tester AI Testing v2.0

الهدف: تقديم تلخيص غير مُخل للمبادئ العلمية والمفاهيم المفصلية في الفصول السبعة القابلة للاختبار، مع خرائط ذهنية سريعة وجدول يربط الفصول بخطة المذاكرة الحالية.

> **مهم:** هذا المستند أداة مراجعة وفهم، وليس بديلًا عن السورس الرسمي. **الـ official syllabus** يظل مصدر الحقيقة النهائي للمصطلحات وصياغة الامتحان.

ماذا ستجد هنا؟

- ملخص علمي مركز لكل فصل
- خريطة ذهنية سريعة لكل فصل
- جدول ربط الفصول بخطة المذاكرة / الموقع
- تركيز على ما يهم الاختبار العملي لـ AI systems

جدول ربط الفصول بالخطة الحالية

الفصل	التركيز	أفضل أيام/بلوكات في الخطة	لماذا مهم في هذه المرحلة؟
Chapter 1	AI foundations	1, 11–12	فهم طبيعة النظام AI، نوعه، بيئة تشغيله، وتأثير اللوائح
Chapter 2	Quality & acceptance	1, 16–17, 35	تعريف معايير القبول، الجودة، السلامة، والتحكم البشري
Chapter 3	/ ML / data / metrics neural nets	2–6, 18–26, 34	بناء الفهم الكمي للبيانات، المقاييس، وworkflow
Chapter 4	Testing AI systems / LLMs	7–13, 28–30	المنهج الإحصائي، oracle problem، GenAI, red teaming
Chapter 5	Input data testing	8–10, 14, 27, 31	التحيز، representativeness، القيود، labels, pipelines
Chapter 6	Model testing	13–17, 30–35	robustness-، metamorphic، drift، A/B، back to-back
Chapter 7	& ML development deployment	17, 32, 35	إطلاق النموذج بأمان ومراجعة بيئة التطوير والنشر

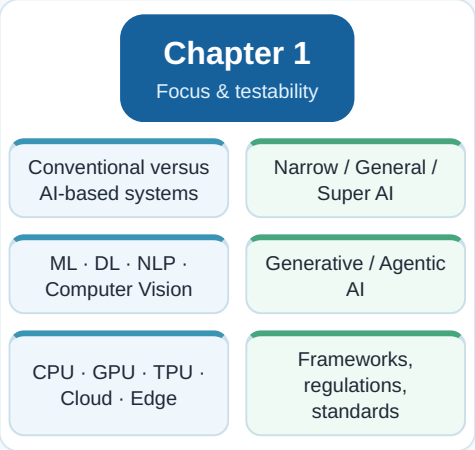
الجدول أعلاه هو **snapshot study map** ليساعدك على وضع الملخصات داخل الموقع جنبًا إلى جنب مع الجدول الزمني الموجود عندك.

Prepared for Hazem — based on the ISTQB Certified Tester AI Testing Syllabus v2.0 (April 2026).

الفصل 1 — Introduction to Artificial Intelligence

الفكرة العامة: يؤسس هذا الفصل لغة مشتركة لفهم الذكاء الاصطناعي قبل اختباره: ما الفرق بين النظام التقليدي والنظام المعتمد على الذكاء الاصطناعي، وما أنواع تقنيات AI، وكيف تؤثر البنية التقنية واللوائح على الاختبار.

الخريطة الذهنية



خريطة ذهنية سريعة للمراجعة قبل التطبيق أو قبل حل الأسئلة.

الملخص المركز

- **الفكرة المحورية:** الأنظمة التقليدية تعمل بقواعد صريحة يكتبها المطوّر، بينما الأنظمة المعتمدة على AI — خاصة أنظمة ML — تتعلم الأنماط من البيانات، لذلك تكون مخرجاتها احتمالية وأقل قابلية للتفسير الكامل. هذا يجعل الاختبار لا يركز فقط على "هل الكود نفّذ المطلوب؟" بل أيضًا "هل التعلّم من البيانات مناسب وآمن ويمكن الوثوق به؟".
- **AI vs Conventional:** النظام التقليدي أكثر حتمية وشفافية وأسهل في تتبع السبب والنتيجة. أما AI فيعتمد على الاستدلال الإحصائي والتعرّف على الأنماط، وقد يقدّم إجابات صحيحة غالبًا لكن ليس دائمًا. لذلك تصبح قابلية التفسير، حدود الخطأ المقبول، والمراقبة المستمرة عناصر أساسية في الجودة.
- **مستويات AI:** Narrow AI هو كل ما نستخدمه اليوم تقريبًا؛ متخصص في مهمة محددة مثل التصنيف أو الترجمة أو التوصية. General AI مفهوم نظري لقدرة عامة شبيهة بالإنسان عبر مهام مختلفة دون إعادة تدريب كبيرة. Super AI تصور يتجاوز الذكاء البشري ويثير مخاطر وجودية وتنظيمية.
- **الأنواع التقنية الأساسية:** ML يشمل supervised learning (تصنيف/انحدار)، /unsupervised learning (clustering

association)، وreinforcement learning.
Deep learning يستخدم شبكات عصبية عميقة مثل CNN للصور، RNN/Transformers للتسلسلات والنصوص. توجد أيضًا NLP وcomputer vision وrule-based systems وfuzzy logic وsearch algorithms وagentic AI.

- **Generative AI:** يُنشئ نصًا أو صورًا أو صوتًا جديدًا بدل الاكتفاء بالتصنيف. قوته العالية تأتي مع مخاطر مثل hallucination، الحساسية للصياغة، إنتاج محتوى ضار أو غير دقيق، وصعوبة إثبات المصدر. عند الاختبار يجب فحص الفائدة والجودة والسلامة معًا.
- **البنية التحتية والتطوير:** اختيار CPU/GPU/TPU، وقرار cloud vs edge، وأدوات مثل TensorFlow وPyTorch وscikit-learn، كلها تؤثر على الأداء، التكرارية، سهولة النشر، والاختبارات الممكنة. كما أن اللوائح والمعايير التنظيمية تفرض متطلبات تخص الشفافية، السلامة، الخصوصية، والتحكم البشري.

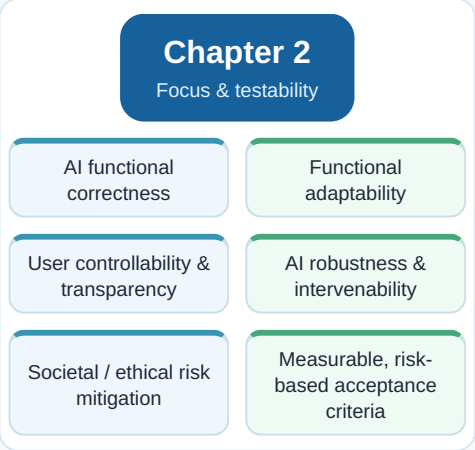
ما الذي يجب تذكره في الاختبار والعمل؟

- AI systems ليست مجرد code rules؛ هي data-driven واحتمالية غالبًا.
- نوع النظام (Narrow/GenAI/Agentic) يغير استراتيجية الاختبار.
- العتاد، البيئة، واللوائح ليست تفاصيل جانبية؛ كلها تؤثر على الجودة والاختبار.

الفصل 2 — Quality Characteristics for AI-Based Systems

الفكرة العامة: يركّز هذا الفصل على ما الذي يعنيه "جودة" في نظام AI وفق ISO/IEC 25059، وكيف تتحول الجودة إلى معايير قبول قابلة للقياس وليست شعارات عامة.

الخريطة الذهنية



خريطة ذهنية سريعة للمراجعة قبل التطبيق أو قبل حل الأسئلة.

الملخص المركز

- **الفكرة المحورية:** جودة أنظمة AI لا يمكن اختزالها في correctness التقليدية فقط، لأن الخطأ الاحتمالي جزء طبيعي من هذه الأنظمة. لذلك يوسّع ISO/IEC 25059 نموذج الجودة ليشمل خصائص AI-specific تؤثر مباشرة على أهداف الاختبار ومعايير القبول.
- **الخصائص النوعية الأساسية:** AI functional correctness تعني تقييم المخرجات الصحيحة والخاطئة مع قبول نسب خطأ مضبوطة. Functional adaptability تقيس قدرة النظام على التكيّف بعد النشر. User controllability وintervenability تركّزان على قدرة البشر أو أنظمة أخرى على التدخل في الوقت المناسب. Transparency تعني إتاحة معلومات مفهومة لأصحاب المصلحة. AI robustness تعني بقاء الأداء مقبولًا رغم المدخلات المتحيزة أو المعادية أو الظروف السيئة. Societal and ethical risk mitigation يغطي العدالة والخصوصية والقيم والالتزام المجتمعي.
- **AI والسلامة:** في الأنظمة safety-related يصبح الأمر أصعب لأن المواصفات قد تبدأ كأهداف عامة، والسلوك قد يكون غير حتمي أو صعب التفسير، وقد يتغير مع الزمن. لذلك لا تكفي اختبارات الوظيفة فقط؛ يلزم تحليل مخاطر، حدود تشغيل، مسارات تدخل بشري، ومراقبة تشغيلية.

- **معايير القبول AI acceptance criteria:** يجب أن تكون قابلة للقياس ومرتبطة بالمخاطر. أمثلة: حد أدنى للدقة/الاستدعاء، حد أقصى للـ false negatives في سياق حساس، نسبة تفاوت مقبولة بين مجموعات سكانية، زمن أقصى للتدخل البشري، أو شرط توفير تفسير/سجل قرار. في GenAI يمكن أن تكون المعايير: groundedness، عدم كشف بيانات حساسة، نسبة منخفضة للمحتوى الضار، أو الالتزام ببنك الأسئلة المعتمد.
- **الخلاصة العملية:** هذا الفصل مهم لأنه يحوّل الحديث من "النظام جيد" إلى "ما هي الخصائص الحرجة؟ كيف نقيسها؟ وما هو حد النجاح/الفشل؟". أي خطة اختبار قوية لأنظمة AI تبدأ من جودة معرّفة بوضوح ومعايير قبول معلنة مسبقًا.

ما الذي يجب تذكره في الاختبار والعمل؟

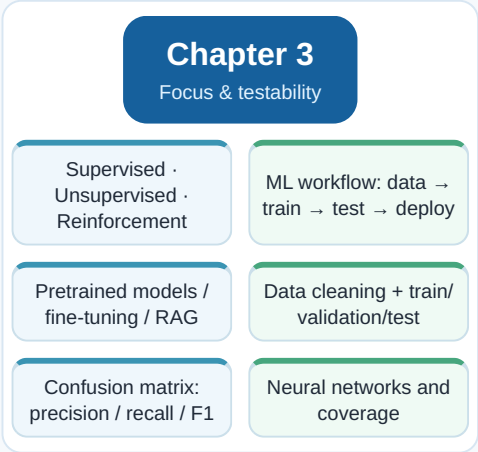
- ابدأ من الجودة المطلوبة، لا من عدد test cases فقط.
- معايير القبول يجب أن تكون قابلة للقياس ومسبقة الاتفاق.
- الشفافية والتحكم البشري والعدالة ليست "nice to have" في الأنظمة الحساسة.

Chapter 3

الفصل 3 — Machine Learning

الفكرة العامة: هذا الفصل هو الأساس التقني لفهم دورة حياة ML والبيانات والمقاييس والشبكات العصبية؛ ومن دونه يصعب تفسير نتائج الاختبار أو تشخيص مصدر الخلل.

الخريطة الذهنية



خريطة ذهنية سريعة للمراجعة قبل التطبيق أو قبل حل الأسئلة.

الملخص المركز

- **أشكال ML:** supervised learning يستخدم بيانات مُعلَّمة لمهام classification وregression. unsupervised learning يبحث عن الأنماط دون labels مثل clustering وassociation. reinforcement learning يتعلم عبر التفاعل مع البيئة والمكافآت/العقوبات. اختيار النوع يعتمد على طبيعة البيانات والهدف.
- **الـ workflow القياسي:** يبدأ بتحديد الهدف ومعايير النجاح، ثم جمع البيانات وتنظيفها وإعدادها، ثم تقسيمها إلى training/ validation/test، ثم اختيار الخوارزمية والخصائص، والتدريب، والضبط، والتقييم، ثم النشر والمراقبة. الفكرة المهمة للاختبار: العيب الظاهر في النموذج قد يكون سببه مرحلة سابقة مثل إعداد البيانات أو اختيار الميزات.
- **Pretrained models / Fine-tuning / RAG:** النماذج الجاهزة تختصر الوقت لكنها تورثك حدودها وانحيازاتها. Fine-tuning يخصص النموذج لمجال معين. RAG لا "يعلم" النموذج حقائق جديدة بقدر ما يزوّده باسترجاع معلومات خارجية وقت التشغيل؛ لذا تصبح جودة الاسترجاع والربط بالمصدر جزءًا من الاختبار.
- **إعداد البيانات:** يشمل تنظيف البيانات، التطبيع، معالجة المفقودات، feature engineering، الموازنة بين الفئات، التسمية/

الوسم، وفهم provenance. كما يجب التفريق بين training data لتعلّم النموذج، validation data لضبطه، وtest data للحكم النهائي غير المتحيز.

- **مقاييس الأداء للتصنيف:** من مصفوفة الالتباس TP/FP/FN/TN نستنتج accuracy وprecision وrecall وspecificity وF1. اختيار المقياس ليس شكليًا؛ في الأنظمة الحساسة قد يكون recall أهم من accuracy، أو قد تكون false positives أكثر تكلفة من false negatives.
- **الشبكات العصبية والتغطية:** الشبكة العصبية تتكون من neurons وweights وactivations عبر طبقات متعددة. التدريب يضبط الأوزان لتقليل الخطأ. ولأن السلوك الداخلي معقد، توجد مقاييس تغطية مثل neuron coverage وneuron boundary coverage وk-multisection neuron coverage. هذه المقاييس مفيدة استكشافيًا لكنها لا تكفي وحدها لإثبات الجودة أو السلامة.

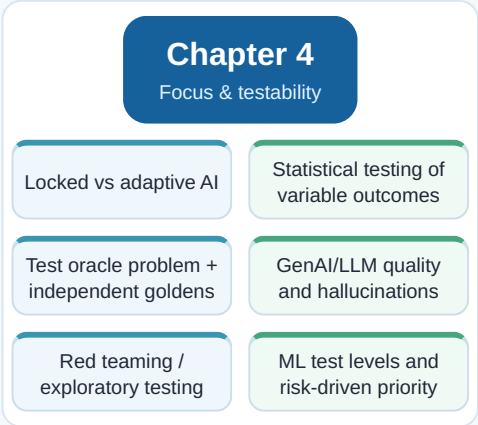
ما الذي يجب تذكره في الاختبار والعمل؟

- افهم الفرق بين training/validation/test، لأنه يتكرر في أسئلة كثيرة.
- اختر metric مناسبًا للمخاطر، وليس الأشهر فقط.
- RAG ليس حلًا سحريًا؛ جودة الاسترجاع نفسها تُختبر.

الفصل 4 — Testing AI-Based Systems

الفكرة العامة: يشرح هذا الفصل لماذا يختلف اختبار AI عن اختبار البرمجيات التقليدية، ولماذا نحتاج إلى منهج إحصائي واختبارات استكشافية وحلول بديلة لمشكلة الـ oracle.

الخريطة الذهنية



خريطة ذهنية سريعة للمراجعة قبل التطبيق أو قبل حل الأسئلة.

الملخص المركز

- **Locked vs Adaptive:** النظام locked لا يغير سلوكه بعد النشر، لذا اختباره أسهل نسبيًا ويشبه إصدارًا ثابتًا. أما adaptive system فيتعلّم أو يتكيّف بعد النشر، لذلك قد يتغير سلوكه أثناء التشغيل، ويصعب التنبؤ بكل الحالات مسبقًا. كثير من أنظمة LLM تقع بين الاثنين: النموذج locked وقت التشغيل، لكن يتم تحديثه دوريًا.
- **لماذا المنهج الإحصائي؟** لأن كثيرًا من أنظمة AI تعمل احتماليًا، فلا يكفي اختبار حالة واحدة بحكم deterministic. نحتاج عينات ممثلة، توزيع أداء، حدود ثقة، ونسب نجاح/فشل عبر فئات وسيناريوهات مختلفة. القبول هنا لا يُبنى على "خرج مطابق مرة واحدة" بل على أداء مقبول ومتكرر عبر نطاق مناسب.
- **مشكلة test oracle:** في البرمجيات التقليدية تكون النتيجة المتوقعة غالبًا واضحة من المواصفات. أما في AI فقد تكون الحقيقة الأرضية غير مكتملة أو ذاتية أو فوق قدرة الإنسان. الحلول تشمل: استخدام ground truth، خبراء المجال، التقييم الإحصائي، المقارنة بنظام آخر، أو العلاقات metamorphic.
- **اختبار GenAI وLLM:** لا يقتصر على الوظيفة، بل يشمل factuality، groundedness، الالتزام بالتعليمات، السلامة، مقاومة jailbreak/prompt injection، الثبات النسبي، استخدام الأدوات أو الاسترجاع، وأثر

صياغة prompts. exploratory testing مهم هنا لأنه يكشف سلوكيات غير متوقعة بسرعة.

- **Red teaming:** أسلوب هجومي منظم لاكتشاف نقاط الضعف وسوء الاستخدام والثغرات الأمنية أو الأخلاقية. الغرض ليس مجرد "كسر النظام"، بل اختبار حدود الحماية والضوابط وماذا يحدث تحت الضغط أو الاستخدام العدائي.
- **Test levels وRisk-based testing:** في أنظمة ML نختبر البيانات، النموذج، pipeline، التكامل، النظام ككل، والقبول والنشر. وتحديد الأولويات يجب أن يبنى على المخاطر: أين يمكن أن يسبب الخطأ ضررًا أكبر؟ ما السيناريوهات الحرجة؟ ما الذي يحتاج أعمق قدر من الأدلة؟

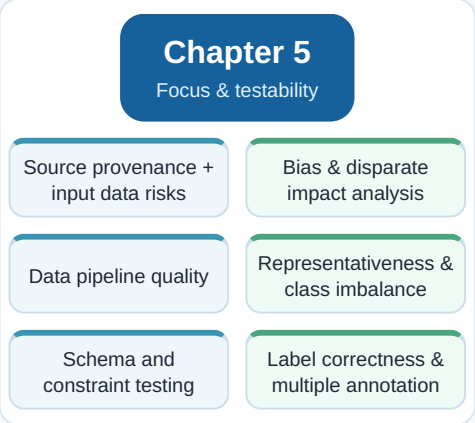
ما الذي يجب تذكره في الاختبار والعمل؟

- المعيار الإحصائي مهم لأن المخرجات قد لا تكون حتمية.
- الـ oracle problem من أهم خصائص اختبار AI.
- LLM testing = جودة + سلامة + مقاومة إساءة الاستخدام.

الفصل 5 — Input Data Testing for Machine Learning Systems

الفكرة العامة: هذا الفصل يرسّخ المبدأ الحاسم في ML: جودة البيانات ليست خطوة تمهيدية فقط، بل هي جزء مباشر من جودة النظام نفسه.

الخريطة الذهنية



خريطة ذهنية سريعة للمراجعة قبل التطبيق أو قبل حل الأسئلة.

الملخص المركز

- **الهدف العام:** التأكد من أن البيانات المستخدمة للتدريب أو التقييم أو التنبؤ ذات جودة كافية. أي خلل في البيانات — provenance أو تمثيل أو labels أو pipeline — قد يظهر لاحقًا كخلل في "ذكاء" النظام، رغم أن أصل المشكلة بيانات وليس نموذجًا.
- **المخاطر الرئيسية:** التحيز، poisoning، مصادر غير موثوقة، عدم الاتساق، قيم خارج المدى، أنواع خاطئة، نقص التمثيل، skewed distributions، missing data، وضعف إرشادات الوسم. كل خطر يقابله أسلوب تخفيف/اختبار مناسب مثل provenance أو EDA أو testing أو dataset constraint testing أو label correctness testing.
- **Testing for bias:** التحيز قد يأتي من البيانات (historical skew, unrepresentative data, poisoned data) أو من الخوارزمية/العتبات. أساليب الكشف تشمل مراجعة workflow، مراجعة توثيق البيانات، static analysis، التحليل الاستكشافي للبيانات، واختبارات المقارنة بين المجموعات الحساسة مثل disparate impact analysis.
- **Data pipeline testing:** يختبر استخراج البيانات وتحويلها وتحميلها، سلامة الـ schema، missing values، التكرار، الأداء، الأمان، وجودة المخرجات بعد كل مرحلة. أي خطأ في pipeline قد يشوّه features أو labels أو يغرس تحيزًا غير مقصود.

- **Representativeness & constraints:** يجب أن تمثل البيانات السكان، السيناريوهات، الفئات، ونطاق القيم المتوقع تشغيل النظام عليها. كما يجب اختبار القيود مثل نوع الحقول، الحدود المسموح بها، قواعد الاتساق والاكتمال. هنا نمنع "garbage in" قبل أن يصبح "garbage out".
- **Label correctness:** إذا كانت labels خاطئة أو غير متسقة فلن يكون "التعلّم" صحيحًا مهما كانت الخوارزمية جيدة. لذلك يلزم إرشادات وسم واضحة، multiple annotation عند الحاجة، آلية adjudication، وقياس الاتفاق بين المعلِّقين. في أنظمة التقييم والمقابلات، استقلال الـ SME goldens عن مخرجات النموذج أمر أساسي.

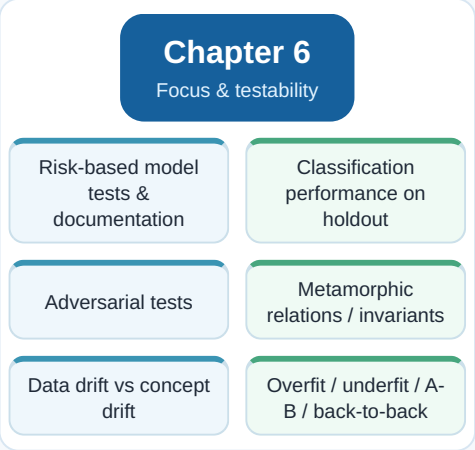
ما الذي يجب تذكره في الاختبار والعمل؟

- معظم مشاكل "الذكاء" قد يكون أصلها البيانات.
- bias وrepresentativeness وlabels ثلاثي حاسم.
- اختبر pipeline لا البيانات الساكنة فقط.

الفصل 6 — Model Testing for Machine Learning Systems

الفكرة العامة: يختص هذا الفصل باختبار النموذج نفسه: الأداء، المتانة، الانجراف، الإفراط أو القصور في التعلّم، والتأكد من أن التحديثات لا تضرّ بالنظام.

الخريطة الذهنية



خريطة ذهنية سريعة للمراجعة قبل التطبيق أو قبل حل الأسئلة.

الملخص المركز

- **نطاق الفصل:** لا يكفي أن تكون البيانات جيدة؛ النموذج نفسه قد يكون متحيزًا أو هشًا أو overfitted أو underfitted أو ضعيف الأداء. لذلك نحتاج استراتيجيات اختبار مخصصة للنماذج الاحتمالية، مع قياسات وظيفية وغير وظيفية.
- **مراجعة التوثيق:** مراجعة model documentation تكشف أمورًا حاسمة: الهدف المقصود، الحدود، بيانات التدريب، المقاييس، الافتراضات، القيود، واجهات الاستخدام، وknown limitations. التوثيق الجيد شرط مهم للشفافية، إعادة الاختبار، والتفسير الصحيح للنتائج.
- **ML functional performance testing:** يتم غالبًا على بيانات holdout أو test data مستقلة، مع حساب مقاييس مرتبطة بالمخاطر مثل precision/recall/F1. في الأنظمة الاحتمالية لا يكفي إعلان "الدقة 90%" دون فهم التوزيع والفئات التي يفشل فيها النموذج وتكلفة أنواع الأخطاء المختلفة.
- **Adversarial testing:** يختبر حساسية النموذج لمدخلات مصممة لخداعه أو تقليل أدائه. هذا مهم للأمن والسلامة وAI robustness. الهجوم قد يكون بسيطًا في الصياغة أو perturbation صغيرًا لكنه يؤدي إلى نتيجة خاطئة تمامًا.
- **Metamorphic testing:** مهم عندما يصعب تحديد expected result بدقة. بدلًا من ذلك

نعرّف علاقة يجب أن تبقى صحيحة بين مخرجات مدخلات مرتبطة. مثال: إعادة صياغة إجابة مرشح بنفس المعنى لا ينبغي أن تقلب الحكم جذريًا. هذا أسلوب قوي لحل جزء من مشكلة الـ oracle.

- **/ Drift / overfitting / underfitting / A/B back-to-back:** drift testing يراقب تغير البيانات أو المفهوم التشغيلي بمرور الزمن. overfitting يظهر عندما يحفظ النموذج بيانات التدريب ويفشل على البيانات الجديدة، بينما underfitting يعني أن النموذج لم يتعلم بما يكفي. A/B testing يقارن نسختين في التشغيل، وback-to-back testing يقارن ناتج النسخة الجديدة بالقديمة أو بمرجع آخر لكشف regression أو تراجع الأداء.

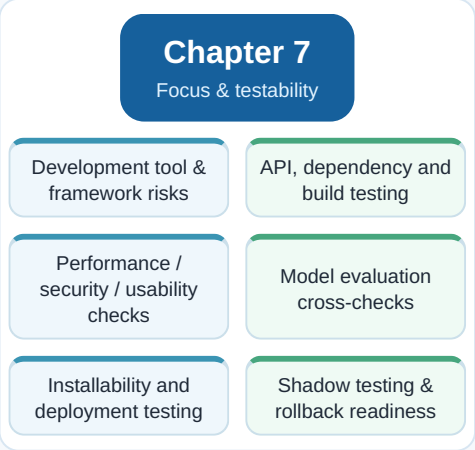
ما الذي يجب تذكره في الاختبار والعمل؟

- المقارنة بين النسخ وإدارة drift لا تقل أهمية عن دقة النموذج الحالية.
- metamorphic testing سلاح قوي عندما يصعب تحديد expected result.
- راجع التوثيق؛ الوثائق السيئة تفسد الفهم والحكم على النتائج.

الفصل 7 — Machine Learning Development Testing

الفكرة العامة: الفصل الأخير يحوّل التركيز من "النموذج" إلى "بيئة التطوير والنشر": الأدوات، الأطر، الإعدادات، وعمليات الإصدار التي قد تُدخل مخاطر جديدة.

الخريطة الذهنية



خريطة ذهنية سريعة للمراجعة قبل التطبيق أو قبل حل الأسئلة.

الملخص المركز

- **الفكرة المحورية:** قد يفشل النظام حتى لو كان النموذج جيدًا، بسبب خطأ في framework، سوء استخدام API، build defect، تقسيم غير صحيح للبيانات، أو مشكلة في النشر على البيئة المستهدفة. لذلك يجب اختبار دورة التطوير والنشر نفسها.
- **مخاطر التطوير:** تشمل الاستخدام الخاطئ لمكتبات مثل TensorFlow/PyTorch، اختيار framework أو algorithm غير مناسب، hyperparameters دون ضبط جيد، عيوب في التثبيت والبناء، أخطاء في تنفيذ التقييم داخل الأداة، سوء تفسير النتائج بسبب stochastic training، أو ثغرات أمنية في المكتبات.
- **وسائل التخفيف والاختبار:** API testing، smoke testing، framework/documentation reviews، performance testing، usability testing، security testing، cross-checking results، back-to-back testing، وA/B testing. هذه الأساليب لا تختبر "الذكاء" فقط، بل صحة خط التطوير نفسه.
- **Deployment testing:** عند نشر MLS يجب اختبار قابلية التثبيت والتهيئة والإزالة، التوافق مع البيئة (cloud, edge, mobile)، الاعتماديات مثل interfaces/APIs، GPU drivers، الأداء، والأثر الفعلي بعد النشر. الفكرة ليست أن النموذج يعمل في المختبر فقط، بل أن يعمل بأمان في الواقع.

- **Shadow testing وغيرها:** shadow testing يسمح بمراقبة نموذج جديد في بيئة تشغيل حقيقية دون أن يتحكم فعليًا في المخرجات، ما يقدّم دليلًا عالي القيمة قبل التبديل الكامل. كما تُستخدم اختبارات smoke وregression وA/B عند التحديثات.
- **الخلاصة العملية:** جودة AI ليست "ملف model.pkl جيد". هي سلسلة كاملة: بيانات، نموذج، deployment، pipeline، framework، monitoring. الفصل 7 يضمن ألا تضيع جودة المراحل السابقة عند الانتقال من التطوير إلى التشغيل.

ما الذي يجب تذكره في الاختبار والعمل؟

- جودة ML pipeline والتطوير والنشر تساوي أهمية جودة النموذج نفسه.
- اختبر التوافق، التثبيت، الأداء، الأمان، وshadow deployment.
- التحسين في المختبر لا يكفي؛ يجب إثبات التحسن في البيئة المستهدفة.